

Clef Bildbenchmark mit deutschen Fragen

Ergebnisse auf synthetischen Diagrammen und deutschen Belegen
2. Oktober 2026

Fazit

Clef beantwortet bei 27/30 (90,0 %) der Diagramme und 17/20 (85,0 %) der Belege sämtliche Aufgaben richtig. In 5 der fünf Aufgaben liegt die Trefferquote über der jeweiligen Mehrheitsklassenbaseline. Die Ergebnisse beschreiben einen kleinen, kontrollierten Bildtest und reichen für eine Freigabe zur automatischen Dokumentenverarbeitung oder für allgemeine Finanzanwendungen nicht aus.

Umfang: 50 eigenständige Quellbilder, 120 Primärentscheidungen und 90 gewertete Vorwärtsläufe. Die 30 Diagramme sind synthetisch und englisch beschriftet. Die 20 Rechnungen und Gutschriften sind synthetische Originalbilder mit tatsächlich deutschem Text. Alle Hauptfragen sind deutsch.

Wichtige Einschränkung: Die drei strikten Diagrammartfehler betreffen potenziell überlappende Antwortoptionen. Sie belegen daher nicht eindeutig eine visuelle Fehlwahrnehmung. Der eingefrorene Score bleibt unverändert; die nachträglich erkannte Mehrdeutigkeit wird auf Seite 4 erläutert.

Die fünf Hauptaufgaben

Aufgabe	Richtig	Trefferquote	Balanced Accuracy	Mehrheitsbaseline
Diagrammart	27/30	90,0 %	90,0 %	10,0 %
Legendenanzahl	30/30	100,0 %	100,0 %	36,7 %
Dokumentart	20/20	100,0 %	100,0 %	80,0 %
Steuerhinweis	19/20	95,0 %	93,3 %	60,0 %
Bruttosummenintervall	18/20	90,0 %	90,0 %	20,0 %

Balanced Accuracy = mittlere Trefferquote über die im Test vorhandenen Referenzklassen. Die Mehrheitsbaseline wählt für jede Aufgabe stets deren häufigste Referenzklasse. Die beiden Maße verhindern, dass ungleiche Klassenhäufigkeiten unbemerkt bleiben.

Technische Gültigkeit und Unsicherheit

Schema gültig: 90/90 Ausgaben. Tatsächlicher Vision-Aufruf bei jedem Request: ja. Gekürzte Eingaben: 0. Unter den 68 Primärentscheidungen mit mindestens 90 % Modellkonfidenz liegen 0 Fehler. Konfidenz ist eine Softmax-Ausgabe und keine nachgewiesene Verlässlichkeit.

Gepaarter Sprachvergleich und Weißbildkontrolle

Für dieselben 20 ausgewählten Bilder werden drei Bedingungen verglichen: deutsches Fragenset mit Originalbild, englisches Fragenset mit Originalbild und deutsches Fragenset mit einer weißen Bildfläche in identischer Originalgröße. Je zehn Diagramme und zehn Belege liefern 50 Entscheidungen pro Bedingung. Die zusätzlichen 40 Läufe sind keine neuen Bilder.

Aufgabe	DE Bild	EN Bild	DE Weiß	EN minus DE	Bild minus Weiß
Diagrammart	9/10	9/10	1/10	+0,0 PP	+80,0 PP
Legendenanzahl	10/10	10/10	0/10	+0,0 PP	+100,0 PP
Dokumentart	10/10	10/10	4/10	+0,0 PP	+60,0 PP
Steuerhinweis	9/10	10/10	5/10	+10,0 PP	+40,0 PP
Bruttosummenintervall	8/10	8/10	3/10	+0,0 PP	+50,0 PP

Jede Zelle mit Treffern hat denselben Nenner 10. PP = Prozentpunkte. EN minus DE misst den Unterschied auf identischen Bildern; Bild minus Weiß hält die deutsche Frage konstant.

Diagramme

Deutsch mit Bild: 19/20 (95,0 %); Englisch mit Bild: 19/20 (95,0 %); Deutsch mit Weißbild: 1/20 (5,0 %). Nur die englische Variante ist in 0 Entscheidungen richtig, nur die deutsche in 0. Beide Sprachen wählen in 20/20 Entscheidungen dieselbe Option.

Durch das Weißbild ändern sich 19/20 gewählte Optionen. Die mittlere Wahrscheinlichkeit der Referenzantwort ändert sich von Weiß zu Bild um +71,7 PP.

Deutsche Belege

Deutsch mit Bild: 27/30 (90,0 %); Englisch mit Bild: 28/30 (93,3 %); Deutsch mit Weißbild: 12/30 (40,0 %). Nur die englische Variante ist in 1 Entscheidungen richtig, nur die deutsche in 0. Beide Sprachen wählen in 29/30 Entscheidungen dieselbe Option.

Durch das Weißbild ändern sich 19/30 gewählte Optionen. Die mittlere Wahrscheinlichkeit der Referenzantwort ändert sich von Weiß zu Bild um +48,8 PP.

Was die Kontrollen aussagen

Ein Vorsprung mit Originalbild ist ein Hinweis auf nutzbaren Bildinhalt. Gleichbleibende oder richtige Weißbildantworten können aus Klassen-, Options- und Sprachpräferenzen entstehen. Da keine Enthaltungsoption angeboten wird, erzwingt das Schema auch beim Weißbild eine Auswahl; solche Antworten werden nicht als Halluzinationen gewertet. Das Experiment trennt diese Mechanismen nicht vollständig und prüft weder andere Bildstörungen noch reale Robustheit. Sprachunterschiede bleiben wegen der kleinen, gezielt ausgewählten Teilmenge deskriptiv; der offizielle Rahmenprompt bleibt in beiden Sprachen englisch.

Stichprobe und Auswertungsmethode

Deterministische Auswahl vor der Inferenz

Diagramme: 30 von 300 Bildern des offiziellen Testsplits von YuukiAsuna/synthetic_chart. Für jede Kombination aus zehn Diagrammtypen und drei Schwierigkeitsgraden wurde das Bild mit dem kleinsten SHA-256-Wert gewählt. Die Felder sind Diagrammart und Anzahl sichtbarer Legendeneinträge.

Belege: 20 aus der öffentlichen 40-Dokumente-Vorschau ohne offiziellen Testsplit. Die Auswahl umfasst acht reguläre, fünf Kleinunternehmer-, drei Reverse-Charge- und vier Gutschrift-Fälle; zwölf Fotos, sechs Scans und zwei saubere Renderings. Nicht reguläre Fälle sind vollständig enthalten, reguläre wurden nach Variante und Layout geschichtet und anhand von SHA-256 ausgewählt.

Die drei Belegaufgaben prüfen Dokumentart, ausdrücklich gedruckten Steuerhinweis und das Intervall der Bruttosumme. Die fünf Intervalle sind: negativ; 0 bis einschließlich 1.000; über 1.000 bis einschließlich 5.000; über 5.000 bis einschließlich 20.000; über 20.000 EUR. Jede Intervallklasse kommt viermal vor.

Referenzen und Bewertung

Alle 50 Bilder und 120 Referenzentscheidungen wurden vor dem Hauptlauf direkt an den Bildpunkten unabhängig geprüft, ohne Modellantworten zu lesen. Zwei Optionsbeschreibungen wurden vor dem Einfrieren präzisiert. Bilder, Fälle, Referenzen, Fragen und Scorer sind mit Hashwerten fixiert. Gewertet wird die exakte zulässige Options-ID; ungültige Felder gelten als falsch. Vollständig richtige Bilder erfordern richtige Antworten auf alle ihre Felder.

Ausführung auf CPU

Cloudflare/clef-flash, Revision 17f0b0ad64efb65d273590632833508766b2aae6. Batch 1, 6 Threads. Sprach-Linear-Layer: NF4 mit Double Quantization und BF16-Berechnung. Originaler Vision-Encoder, Joint Head und Ausgabe-Embedding: BF16. Der offizielle Modellwrapper ist unverändert. Diese experimentelle CPU-Konfiguration ist nicht mit Herstellerangaben für H200 oder eine vollständige BF16-Ausführung gleichzusetzen.

Der offizielle Processor erhält 65.536 bis 786.432 Pixel unter Erhalt des Seitenverhältnisses und rundet auf sein Patchraster. Keine Ausschnitte, Rotation, Bildoptimierung oder zusätzliche OCR. Dateinamen, Quell-IDs, Labels, Metadaten und OCR-Transkripte gelangen nicht in den Modelltext. Ein Hook protokolliert den tatsächlichen Encoderaufruf; echte Bildtensoren werden erzeugt.

Der Vision-Encoder bleibt auch aus technischem Grund BF16: Die installierte CPU-4-Bit-Packroutine passt nicht zu seiner MLP-Dimension 4304. Vor dem Lauf wurden null quantisierte Vision-Linear-Module und ausschließlich BF16-Visionparameter geprüft. Die vollständige Kodierung wurde für alle 90 Requests vorab kontrolliert, ohne Kürzung.

Fehler und Grenzen der Aussagekraft

Fehler mit hoher Modellkonfidenz

Aufgabe	Fehler gesamt	Fehler mit Konfidenz ≥ 90 %
Diagrammart	3/30	0
Legendenanzahl	0/30	0
Dokumentart	0/20	0
Steuerhinweis	1/20	0
Bruttosummenintervall	2/20	0

Mehrdeutige Diagrammartoptionen

Alle drei Abweichungen (chart-001 bis -003) wählen „Senkrechte Säulen mit zwei y-Achsen“ statt „Kombination aus Säulen und Linie“. Die eingefrorene erste Beschreibung schließt Linien nicht aus und kann sich mit dem Kombinationsdiagramm überschneiden. Das ist eine potenzielle Benchmarkmehrdeutigkeit, kein bewiesener visueller Erkennungsfehler. Der bestandene Vorab-Pixelaudit erkannte sie nicht; sie fiel erst nach dem Lauf auf. Der strikte Wert 27/30 bleibt bestehen. Eingaben, Referenzen und Hauptlauf wurden nicht nachträglich geändert.

Vorzeichen und Steuerhinweis

Zwei negative Gutschrift-Gesamtbeträge werden positiven Intervallen zugeordnet: invoice-009: „über 20.000 EUR“ bei 85,9 %; invoice-016: „über 5.000 bis einschließlich 20.000 EUR“ bei 80,4 %. Die Dokumentart Gutschrift wird in beiden Fällen richtig erkannt. Für negative Bruttobeträge sind nur zwei von vier Entscheidungen richtig.

invoice-006 wird trotz §19-Fußnote als regulär besteuert eingestuft (63,2 % Konfidenz). Die Frage gibt dem ausdrücklichen Hinweis Vorrang vor den widersprüchlichen Steuersätzen in Positionszeilen. Unter den fünf Kleinunternehmerfällen sind vier Steuerhinweise richtig erkannt.

Quellfehler und Grenzen

Vier Kleinunternehmerbelege (invoice-004, -006, -012 und -013) zeigen Umsatzsteuersätze in Positionszeilen trotz ausdrücklichem §19-Hinweis. Gewertet wird gemäß Frage dieser gedruckte Fußnotenhinweis, nicht steuerrechtliche Richtigkeit. Bei drei Kreisdiagrammen ist Legendentext abgeschnitten, aber jede zu zählende Farbbox und Zeile sichtbar. Synthetische Titel, Achsen und Kategorien sind teils inhaltlich unplausibel.

Die gezielte synthetische Stichprobe liefert keine Populationsschätzung; mögliche Trainingskontamination ist unbekannt. Mehrere Felder desselben Bildes und gepaarte Wiederholungen sind keine unabhängigen Beobachtungen. Verkleinerung kann Text unlesbarer machen. Nicht gemessen werden freie Volltext-OCR, komplexe Finanzmathematik, Rechnungsprüfung, Anlageberatung, Compliance oder sichere Verarbeitung realer vertraulicher Unterlagen.

Quellen und Reproduktion

[Modell Cloudflare clef flash](#)

Revision 17f0b0ad64efb65d273590632833508766b2aae6 · Lizenz Apache 2.0

[Diagramme YuukiAsuna synthetic chart](#)

Revision 633cf14bc4c513f6c4806e319905e573afae12f4 · offizieller Testsplrit · CC BY 4.0 laut Anbieter

[Deutsche Belege Belege von Immineal 2026](#)

Revision da6044a02bd0b6c1d065b9f5615fe021272ece45 · kostenlose Vorschau ohne offiziellen Testsplrit

Belege (Immineal, 2026). Die Lizenz erlaubt lokale Evaluation sowie die Veröffentlichung abgeleiteter Ergebnisse und dokumentarischer Abbildungen mit dieser Attribution. Dieser Bericht enthält zwei Summenausschnitte als Fehlerbelege, keine vollständigen Rechnungsbilder oder Weiterverbreitung des ausgewählten Datensatzes. Alle Personen, Firmen und Beträge der Belege sind laut Anbieter frei erfunden.

[Belege Dataset Licence Version 1 vom 14 August 2026](#)

Laufzeit unter den gemessenen Bedingungen

Deutscher Hauptlauf	Median	95. Perzentil
30 Diagramme	37,7 s	43,2 s
20 Belege	36,8 s	39,3 s

Nur Modellvorwärtslauf, Batch 1, CPU und sechs Threads; Laden, Kodierung und separate Aufwärmäufe sind ausgeschlossen. Das 95. Perzentil nutzt die Nearest-Rank-Methode. Keine allgemeine Durchsatz- oder Hardwarevergleichsaussage.

Prüfbare Reproduktion

1. Quellen aus den festgelegten Revisionen mit scripts/acquire_sources.py beschaffen. 2. Auswahl und Fragen mit scripts/build_benchmark.py erzeugen; Freeze und Bildhashes mit scripts/verify_freeze.py prüfen. 3. Den dokumentierten CPU-Lauf mit 786.432 Pixeln und visuellem Aufwärmen ausführen. 4. Unbearbeitete Ausgaben mit scripts/score_images.py bewerten und diesen Bericht mit report/build_report.py erstellen.

Die vollständigen Befehle und Abhängigkeiten stehen im Reproduktionspaket. scores.json enthält Feldantworten, Kontrollpaare, Konfusionszählungen und Scorer-Prüfwerte; predictions.metadata.json enthält Laufkonfiguration, Versionen und Abschlussstatus. report/build_manifest.json bindet den Bericht an diese Eingaben.

Laufversionen: torch 2.11.0+cpu; transformers 5.10.2; bitsandbytes 0.50.2; pillow 12.3.0; huggingface-hub 1.33.0; safetensors 0.8.0.

Abschluss des Hauptlaufs: 02.10.2026 08:17:20 UTC. Ein einzelner zusätzlicher Wiederholungstest ergab dieselben Antworten; maximale absolute Wahrscheinlichkeitsabweichung 0. Dieser technische Einzeltest gehört nicht zu den 90 gewerteten Läufen und belegt keine allgemeine Reproduzierbarkeit.

Quellen der drei Diagrammartabweichungen

[chart-001 · Quell-ID test-270 · fixierte Diagrammquelle](#)

SHA-256 1158446f9f4068753dd2be4163bc94d62dabbd7e67e87157bfe2d28404a7afc7

[chart-002 · Quell-ID test-293 · fixierte Diagrammquelle](#)

SHA-256 00fbd70006924eb1d1f660b564eccbf00e6850c4ab36370e3bb1d6389589a263

[chart-003 · Quell-ID test-286 · fixierte Diagrammquelle](#)


SHA-256 007ccd50efe6ba6d6ac60740d037fe886916d02e0cf1c0735e97b5cff832d157

Bildbelege für die beiden Vorzeichenfehler

Die Summenblöcke zeigen die tatsächlich gedruckten negativen Gesamtbeträge zusammen mit Netto- und Umsatzsteuerbetrag. Die Ausschnitte sind unveränderte Bildpunkte der Testbilder: nur zugeschnitten, ohne Retusche oder neue Bildgenerierung. Die Darstellungsgröße im Bericht ist vergrößert. Die Referenzklasse bleibt in beiden Fällen „negativ“.

Quelle beider Abbildungen: Belege (Immineal, 2026), laterrrr/belege-de-invoices-sample, Revision da6044a02bd0b6c1d065b9f5615fe021272ece45. Alle Belegdaten sind synthetisch.

Fall 009 mit negativem Gesamtbetrag



Nettobetrag	-25.074,10
zzgl. 19 % USt.	-4.764,08
Gesamtbetrag	-29.838,18


Abbildung 1 · invoice-009 · Quell-ID beleg-000038

Gedruckter Gesamtbetrag -29.838,18 EUR. Modellantwort „über 20.000 EUR“ mit 85,9 % Konfidenz. Quelle: Belege (Immineal, 2026).

SHA-256 des vollständigen Testbilds

3fedbad12d63e215468ca50e2b690a2cb5ec28463cd865137771bc78733633d6

Fall 016 mit negativem Gesamtbetrag



Nettobetrag	-14.199,44
zzgl. 19 % USt.	-2.697,89
Gesamtbetrag	-16.897,33

Abbildung 2 · invoice-016 · Quell-ID beleg-000028

Gedruckter Gesamtbetrag -16.897,33 EUR. Modellantwort „über 5.000 bis einschließlich 20.000 EUR“ mit 80,4 % Konfidenz. Quelle: Belege (Immineal, 2026).

SHA-256 des vollständigen Testbilds

960b58babf0263c6d4c986a15e646c6fbd1dbf282e7d3337650baa54cdf8f6d0